



王靖皓

男 · 博士研究生 · 软件工程 · 中共党员

📞 185-1035-9021 ✉️ wang_jinghao@buaa.edu.cn 🏠 1996.06 📍 常住北京 · 宁夏籍



🎓 教育经历

北京航空航天大学 博士 · 软件工程	2022.09 – 2027.01
RAIDS 实验室 · 导师：胡春明教授 · 研究方向：异构 GPU 集群资源调度、LLM 系统与 AI Infra	
北京航空航天大学 硕士 · 计算机技术	2018.09 – 2021.06
中德软件研究所 · 导师：王锐副教授 · 学位论文：移动机器人自主导航	
重庆大学 本科 · 计算机科学与技术	2013.09 – 2017.06
GPA 3.0 / 4.0 (专业前 30%) · 主修：操作系统、计算机组成原理、计算机网络、数据结构与算法	

🔬 科研经历

结构感知的深度学习负载资源预测与 Agentic 工作流编排 (SagePilot)	2025.11 – 至今
一作论文撰写中	

深度学习负载上线前往往需要大量 profiling 试跑来估计资源需求，成本高、周期长；在 Agentic 工作流中，工具模型频繁动态加载与卸载，进一步带来冷启动慢、显存 OOM 与资源浪费等问题。本工作希望在不实际运行的前提下预测负载资源画像，并用预测信号指导工作流的模型编排。

- **计算图表征**：将模型导出为 ONNX 计算图并转化为图样本，融合算子类型、张量形状与拓扑结构等节点/边特征，刻画负载的结构特性。
- **GNN 多目标预测**：设计图神经网络回归器，一次前向即可联合预测运行时延、显存峰值、GPU 利用率等多维指标，免去逐配置的反复试跑。
- **Benchmark 构建**：通过运行时程序分析自动采集计算图拓扑与真实性能数据，构造覆盖 CNN/Transformer/推荐等多模型族的计算图数据集，规模 10W+ 条。
- **工作流编排**：将预测的部署耗时与显存风险用于 Agentic 工作流的工具模型调度——冷启动预部署、OOM 风险感知选卡、显存复用与驱逐，显著降低 session 端到端延迟与资源浪费。

异构 GPU 集群混合调度与运行时系统	2023.03 – 至今
依托两项国家重点研发计划课题	

- 异构云资源的混合调度与智能运维 (2022YFB4502003) · 学生负责人 2023.03 – 2026.05
- 资源感知的异构集群运行时系统 (2024YFB4505604) · 技术骨干 2025.01 – 至今
- **训推弹性混部 (ElastiCo)**：面向训练与离线 LLM 推理在同一 GPU 上的安全共置，提出资源形态变换、弹性影子定价与干扰感知共置三项机制，以原生 Kubernetes 中间件形式实现、无需改动用户代码。64 卡实测与最高 512 卡仿真下，平均完成时间最高降低 2.94×、集群吞吐提升 2.02×、GPU 利用率由约 25% 提升至 46%。
- **开源平台 Crater (项目负责人, 论文撰写中)**：主导基于 Kubernetes 的 GPU 集群管理平台，面向科研、教学与企业团队，把零散的 GPU 资源整合为可统一调度、按团队配额管理的共享平台。统一管理用户、账户、队列、配额与审批，基于 Kubernetes 与 Volcano 实现策略感知调度 (队列准入、优先级执行、训推混合放置)；提供作业模板化提交与一键 LLM 训练/推理、容器化 Jupyter / WebIDE / 终端开发环境，及数据集、模型、镜像与共享存储的统一资产管理；集成 Grafana 监控、GPU 分析与 Agent 智能运维及占卡检测。Go / React / Helm 技术栈，提供 Web 控制台、CLI 与 API；已在实验室稳定运行 1.5 年，纳管 250+ 张 GPU、日均调度 200+ 任务，Apache-2.0 开源：<https://github.com/raids-lab/crater>
- **成果产出**：软件著作权 1 项、发明专利 2 项；获北航“冯如杯”研究生组一等奖、中国国际大学生创新大赛北京赛区二等奖、中国研究生操作系统开源创新大赛三等奖。

保障驱动的多租户 GPU 集群深度学习作业调度系统 DeepShare	2025.01 – 2026.03
一作论文已录用 IEEE Cluster 2026 (CCF-B)	

针对多租户 GPU 集群中配额、排队、抢占与共享由各自独立信号驱动、导致租户排队拥塞却仍有大量 GPU 闲置的问题，提出以连续的「配额保障度 (QAD)」为统一运行时控制信号、协调上述四类决策的 Kubernetes 原生调度框架 DeepShare。

- **统一控制信号**：定义配额保障度 QAD，以分配量与 min(配额, 当前保障需求) 之比刻画租户欠服务程度，经 EMA 平滑区分瞬时波动与持续欠服务，跨租户比较恢复紧迫性。
- **弹性配额与预测调度**：将空闲配额以可回收 best-effort 形态借出 (DRA)，先按 QAD、再按运行时预测做字典序排序，避免短作业优化越过欠服务租户，并以代价感知的受害者选择最小化抢占开销。
- **干扰感知共置**：用模型预测两作业共享同一 GPU 时的吞吐损失，仅在干扰足够小时才 MPS 共置，并随租户保障状态与负载动态收紧准入，全程无需改动用户代码与 DL 框架。
- **成果验证**：23,859 条 Venus 真实 trace 仿真下平均 GPU 利用率达 70.6% (较最强无侵入共享基线 Lucid 提升 29.5%)，平均排队延迟降低 46%；16 节点 64 卡 Kubernetes 实测平均完成时间降低 34%，高优租户 QoS 达成率 93%。

面向 LLM 多智能体系统的工作负载感知调度系统 Maestro	2025.05 – 2026.01
一作论文已录用 ICDCS 2026 (CCF-B)	

针对 LLM 多智能体 (LLM-MAS) 工作流中解码成本不确定、长尾多模型显存竞争与过度预留等系统挑战，设计在严格 GPU 预算下的工作负载感知调度系统 Maestro。

- **预测层**：利用 Agent 角色与工具调用语义，构建两阶段输出长度与显存预测器，为调度提供每阶段运行时与 KV 显存需求估计。
- **调度层**：基于预测实现工作流感知的优先级排序与阶段边界抢占，高负载下 SLO 达成率较 EDF 提升 23.6 个百分点，缓解交互式任务的队头阻塞。

• 节点层：通过分级权重缓存与弹性显存供给实现单 GPU 多模型动态共置，KV 预留显存（HBM）降低 67.2%。
基于 16 台 V100 服务器原型与 46,769 条真实多智能体 workflow trace 的仿真共同验证。

📄 科研论文成果

- **J. Wang**, X. Zhou, X. Sun, et al. *Maestro: Workload-Aware Scheduling for LLM-Based Multi-Agent Systems*. IEEE ICDCS 2026. (CCF-B 系统方向顶会 · 录取率 18.59% · 已录用)
- **J. Wang**, et al. *DeepShare: Assurance-Driven Deep Learning Job Scheduling for Multi-Tenant Clusters*. IEEE Cluster 2026. (CCF-B · 已录用)
- **J. Wang**, Y. Zhou, X. Sun, et al. *ElastiCo: Elastic Configuration and Interference-Aware Orchestration for GPU Clusters*. Performance Evaluation 2026. (CCF-B · SCI 期刊 · 小修)
- **J. Wang**, G. Wang, T. Wo, X. Wang, R. Yang. *ESCAPE: A Resource Estimation System for Microservices with Graph Neural Network and Profile Engine*. IEEE JCC 2024. (CCF-C · Best Paper)
- G. Wang, L. Zhang, **J. Wang**, et al. *LogAD: A Multi-Feature Fusion Approach for Log Anomaly Detection*. IEEE JCC 2025. (CCF-C)
- J. Shang, **J. Wang**, G. Liu, et al. *App Uninstalls Prediction: A Machine Learning and Time Series Mining Approach*. ICONIP 2017. (CCF-C · 学生一作)

💼 工作与实习经历

字节跳动 2026.02 – 2026.06

国际电商 Lumen 部门 · AI Infra 工程师（实习）
参与电商训练统一资源池调度系统建设。针对 GPU 按团队固定分配导致的资源孤岛问题（平均每小时约 400 张卡闲置、部分团队任务排队严重），设计并实现跨团队的二级调度框架。

- 在底层训练平台之上构建全局资源视图，支持团队配额管理、A/B/C 多级优先级排队与跨团队可抢占资源（Spot）动态分配。
- 实现基于任务类型、GPU 利用率（SMA）、运行时长等多维约束的抢占回收算法，以最小代价完成资源释放与归还。
- 完成核心存储设计（MySQL + Redis），定义任务全生命周期状态机与 RPC 接口（Thrift），对接底层 Merlin 平台执行层。
- 搭建事件监控模块，实现任务状态变更通知、配额对账与异常任务检测。

字节跳动 2021.07 – 2022.10

商业化技术部门 · 后端开发工程师
负责 TikTok 企业号产品后端开发，核心工作包括：

- 设计并实现蓝 V 企业号认证流程与权益管理系统，搭建企业号商业套件（Business Suite）引导页等功能模块。
- 主导企业号 Web 端充值系统与私信业务的设计开发，保障资金安全与企业客户沟通效率。
- 负责业务日常维护、功能迭代及上下游系统联调，持续优化系统稳定性与可扩展性。

字节跳动 2020.12 – 2021.02

商业化技术部门 · 后端开发工程师（实习）
参与 TikTok 广告归因业务及 Google / Facebook 高价值用户数据回传，使用 Python 优化数据处理流程，保障数据传输准确性与系统稳定性。

北京中科寒武纪科技有限公司 2019.03 – 2019.07

软件部 · 深度学习算法工程师（实习）
参与 TensorFlow 框架对寒武纪 MLU 加速芯片的算子适配与模型支持，深入 AI 加速卡底层做算子开发与性能调优。

- 面向 MLU 架构开发深度学习算子并接入 TensorFlow，结合芯片访存层次与并行特性做计算切分、算子融合与数据布局优化，扩展框架在国产加速卡上的算子覆盖并提升硬件利用率。
- 在 MLU 上完成 CRNN 等模型的端到端调试与精度对齐，定位并修复算子级数值与性能问题，保障模型在目标平台正确高效运行（C++）。

⚙️ 专业技能

- 编程语言 | Go、Python、C/C++、Shell（Go / Python 工业级工程经验）
- 云原生 | Kubernetes（自研调度器与 Operator）、Helm、Docker、Prometheus / Grafana、Linux 运维
- 机器学习 | PyTorch、ONNX、GNN、Transformer / LLM 推理优化（vLLM、KV Cache、调度共置）
- 研究方向 | 资源调度与优化（启发式 / 在线 / 学习驱动）、性能预测、LLM 系统、AI Infra
- 学术与语言 | 独立英文论文写作、软件著作权与专利申请；CET-6

♥️ 获奖情况

- **2026**: 北航 ACT 实验室研究生创新奖学金、北航校友奖学金——航空工业奖学金二等奖
- **2025**: 北航“冯如杯”竞赛研究生组主赛道一等奖、中国国际大学生创新大赛北京赛区二等奖、中国研究生操作系统开源创新大赛三等奖、北京航空航天大学优秀学生干部
- **2024**: 北京航空航天大学国睿奖学金、优秀研究生、优秀三好学生、研究生学业奖学金二等奖
- **2023**: 北京航空航天大学研究生学业奖学金一等奖、优秀学生干部
- **2018–2020**: 北京航空航天大学研究生学业奖学金二等奖（连续三年）

🎨 兴趣与其他

- 研究上聚焦 GPU 集群资源调度与 LLM 系统方向，习惯从系统视角拆解问题，把模糊需求拆成可量化指标再逐步验证；既能独立完成研究与英文论文写作，也乐于把原型推进到工程落地与开源。
- 性格沉稳务实、能扛长周期，乐于沟通协作；作为开源平台负责人和博士班班长习惯主动为团队补位，并任《云计算技术》《国产基础软件》课程助教。
- 运动爱好者：健身、乒乓球、羽毛球、长跑、游泳，参加过多场马拉松和越野比赛——长跑教会我把节奏交给过程。