



🎓 教育经历

北京航空航天大学 博士 · 软件工程	2022.09 – 2027.01
RAIDS 实验室 · 导师: 胡春明教授 · 研究方向: 异构GPU 集群资源调度、LLM 系统与AI Infra	
北京航空航天大学 硕士 · 计算机技术	2018.09 – 2021.06
中德软件研究所 · 导师: 王锐副教授 · 学位论文: 移动机器人自主导航	
重庆大学 本科 · 计算机科学与技术	2013.09 – 2017.06
GPA 3.0 / 4.0 (专业前30%) · 主修: 操作系统、计算机组成原理、计算机网络、数据结构与算法	

📄 科研论文成果

- **J. Wang**, et al. *SagePilot: Latency-Aware Orchestration for Multi-Agent LLM Workflows on Heterogeneous GPUs*. ACM PPoPP 2027. (CCF-A · 投稿中)
- **J. Wang**, et al. *Maestro: Workload-Aware Scheduling for LLM-Based Multi-Agent Systems*. IEEE ICDCS 2026. (CCF-B 系统方向顶会 · 录取率18.59% · 已录用)
- **J. Wang**, et al. *DeepShare: Assurance-Driven Deep Learning Job Scheduling for Multi-Tenant Clusters*. IEEE Cluster 2026. (CCF-B · 已录用)
- **J. Wang**, et al. *ElastiCo: Elastic Configuration and Interference-Aware Orchestration for GPU Clusters*. Performance Evaluation. (CCF-B · SCI 期刊 · 小修)
- **J. Wang**, et al. *ESCAPE: A Resource Estimation System for Microservices with Graph Neural Network and Profile Engine*. IEEE JCC 2024. (CCF-C · Best Paper)
- G. Wang, L. Zhang, **J. Wang**, et al. *LogAD: A Multi-Feature Fusion Approach for Log Anomaly Detection*. IEEE JCC 2025. (CCF-C)
- J. Shang, **J. Wang**, G. Liu, et al. *App Uninstalls Prediction: A Machine Learning and Time Series Mining Approach*. ICONIP 2017. (CCF-C · 学生一作)

🔧 科研经历

- **面向异构GPU 的多智能体LLM 工作流编排系统SagePilot** 2026.03 – 2026.08
一作论文投稿中 · ACM PPoPP 2027 (CCF-A)
多个LLM Agent 工作流并发执行时, 不同Agent 会调用不同模型; 若等任务就绪后再加载模型和选择GPU, 容易造成模型反复加载、任务长时间等待以及GPU 显存利用低效。为此设计并实现SagePilot, 利用工作流依赖提前预测后续Agent 的执行需求, 联合优化模型加载、复用与异构GPU 调度。
 - **跨GPU 性能预测**: 根据模型计算图、请求长度及GPU 算力、显存和带宽等特征, 预测任务在不同GPU 上的执行时延、显存峰值和模型加载时间, 并结合工作流DAG 估计后续Agent 的就绪时间, 为选卡和模型预加载提供依据。
 - **模型复用与在线调度**: 连续使用相同模型配置的Agent 尽量复用同一模型实例, 减少重复调度和模型加载; 对即将就绪的Agent 提前加载所需模型, 并根据实时显存、模型驻留状态和任务队列, 动态决定模型复用/加载/回收以及任务的GPU 放置, 任务完成后根据最新状态重新调度。
 - **系统效果**: 在3 节点12 GPU (8×V100、4×A100) 的异构集群上运行180 个Agent 工作流会话, 相比Parrot/Kairos, 在突发负载下将整体完成时间和P95 会话延迟最高降低36.8% 和25.9%, 每会话GPU 占用时间最多减少24.63 GPU-s。
- **面向异构GPU 的深度学习训练作业多目标性能预测** 2025.12 – 2026.05
深度学习训练作业在不同模型结构、批大小及GPU 架构下呈现显著的性能差异, 而逐模型、逐配置实测成本高, 基于FLOPs、参数量等粗粒度特征又难以刻画算子拓扑与硬件特性。为此提出面向训练作业的跨模型、跨硬件性能预测方法, 在无需求跑待预测作业的情况下, 联合估计训练时延、GPU 利用率、SM Active、显存峰值等7 项运行时指标, 为异构GPU 环境下的准入控制、设备选择与调度决策提供性能画像。
 - **数据与特征构建**: 自动生成不同网络结构与批大小的训练任务, 在V100/A100 上采集端到端训练时延、GPU 利用率、SM Active、显存峰值等7 项性能指标; 将模型结构、运行配置与GPU 算力、显存容量和带宽等硬件特征统一构造跨模型、跨设备训练样本。
 - **图结构性能建模**: 将训练模型转换为ONNX 计算图, 以算子为节点、张量依赖为边, 联合编码算子属性、张量规模、拓扑关系、批大小及GPU 硬件特征; 基于带边特征的Graph Transformer 学习计算图表示, 并通过多任务回归头联合预测多项运行时性能指标, 使单一预测器能够适配不同网络结构、运行配置及V100/A100 GPU。
 - **泛化与预测效果**: 面向训练阶段未出现的深度学习模型进行测试, 在跨模型、跨批大小和异构GPU 场景下, 7 项运行时性能指标综合WAPE 低于5%, 验证了预测器对未知模型结构及不同GPU 算力特征的泛化能力。
- **异构GPU 集群混合调度与运行时系统** 2023.03 – 至今
依托两项国家重点研发计划课题
 - 异构云资源的混合调度与智能运维 (2022YFB4502003) · 学生负责人 2023.03 – 2026.05
 - 资源感知的异构集群运行时系统 (2024YFB4505604) · 技术骨干 2025.01 – 至今
 - **训推弹性混部 (ElastiCo)**: 针对训练整卡占用与离线LLM 推理按峰值预留造成的GPU 空闲、以及直接共置带来的性能干扰, 设计ElastiCo: 训练侧通过调整micro-batch、Activation Checkpointing 和混合精度, 推理侧通过vLLM 的gpu_memory_utilization、并发序列数、最大上下文及Prefix Cache 等配置, 为同一作业生成不同算力/显存占用与吞吐的运行方案。为GPU 算力、显存、CPU 和内存维护动态 “影子价格”, 资源越紧张价格越高, 引导作业选择更节省瓶颈资源的配置, 结合MPS 干扰预测评估共置的吞吐损失, 联合完成配置选择与共置。64 卡实测及最高512 卡仿真下, 平均JCT 改善2.94×、吞吐提升2.02×, GPU 利用率由25% 提升至46%。
 - **开源平台Crater (项目负责人, 论文撰写中)**: 主导基于Kubernetes 的GPU 集群管理平台, 面向科研、教学与企业团队, 把零散的GPU 资源整合为可统一调度、按团队配额管理的共享资源池。统一管理用户、账户、队列、配额与审批, 基于Kubernetes 与Volcano 实现策略感知调度 (队列准入、优先级执行、训推混合放置); 提供作业模板化提交与一键LLM 训练/推理、容器

化Jupyter / WebIDE / 终端开发环境, 及数据集、模型、镜像与共享存储的统一资产管理; 集成Grafana 监控、GPU 分析与占卡检测, 以及Agent 智能运维。提供Web 控制台、CLI 与API; 已在实验室稳定运行近2 年, 纳管250+ 张GPU、日均调度200+ 任务, Apache-2.0 开源: <https://github.com/raids-lab/crater>

- **成果产出:** 软件著作权1 项、发明专利2 项; 获北航“冯如杯”研究生组一等奖、中国国际大学生创新大赛北京赛区二等奖、中国研究生操作系统开源创新大赛三等奖。

• 多租户集群的配额保障与GPU 共享调度系统DeepShare

2025.01 – 2026.03

一作论文已录用 · IEEE Cluster 2026 (CCF-B)

多租户GPU 集群采用固定配额时, 常出现部分租户作业长时间排队、其他租户的空闲配额却无法借出利用的问题; 直接借用空闲GPU 或进行GPU 共享, 又可能影响租户的资源保障。为此构建Kubernetes 原生调度系统DeepShare, 通过配额保障度QAD 动态衡量各租户的资源满足情况, 协调空闲配额借用、作业调度、抢占和GPU 共享, 在保障租户配额的同时提高集群利用率。

- **弹性配额与预测调度:** 将租户暂时不用的GPU 配额借给best-effort 作业, 并在保障型作业到来时动态回收; 调度时优先处理资源保障不足的租户, 再根据预测运行时间优先执行短作业, 同时结合剩余运行时间和历史抢占次数选择代价更低的抢占对象。
- **干扰感知GPU 共享:** 基于DCGM 采集的SM Active、显存带宽等硬件指标预测两个训练作业通过NVIDIA MPS 共置后的吞吐损失, 仅对低干扰组合进行共享; 当集群负载升高或租户资源不足时自动收紧共享条件, 并在线监测实际干扰、及时解除性能下降的共置任务。
- **Kubernetes 系统实现:** 基于Kubernetes Scheduler Framework 实现调度插件, 并结合TenantQuota CRD、MPS DaemonSet 和DCGM 监控完成配额控制、节点选择、共享准入及抢占, 全程无需修改用户训练代码和深度学习框架。
- **系统效果:** 在23,859 条Venus 作业和3,200 条真实集群作业的trace 仿真中, 平均GPU 利用率达到70.6%, 相比Lucid 提升29.5%, 平均排队时间降低46%; 在64-GPU Kubernetes 集群实测中, 平均作业完成时间降低34%, 排队时间降低66%, 保障型租户QoS 达成率93%。

• 面向LLM 多智能体工作流的预测驱动调度系统Maestro

2025.05 – 2026.01

一作论文已录用 · ICDCS 2026 (CCF-B)

LLM 多智能体工作流中, 不同Agent 的输出长度差异显著, 导致执行时间和KV 显存难以提前估计; 同时多个Agent 频繁调用不同模型, 固定预留显存浪费资源, 而按需加载又会带来较高冷启动延迟。为此设计Maestro, 在Agent 阶段执行前预测运行时间与显存需求, 并结合工作流进度进行任务调度和多模型显存管理。

- **Agent 性能预测:** 结合Agent 角色、工作流位置、工具调用信息和输入语义, 先判断当前阶段是否会调用工具, 再预测输出Token 长度, 并进一步估算阶段执行时间和KV Cache 显存需求, 为任务排序和显存分配提供依据。
- **工作流感知调度:** 根据当前阶段及后续工作流的预测剩余时间动态调整任务优先级, 优先执行能够快速完成并解除后续依赖的任务; 高负载时仅在Agent 阶段边界抢占后台任务, 避免中断正在进行的LLM Decode, 缓解长任务造成的队头阻塞。
- **多模型显存管理:** 在单GPU 上动态共置多个LLM, 将模型权重按GPU、CPU 内存和本地磁盘分级缓存, 复用CUDA Graph 等运行时上下文降低模型切换开销; 结合输出长度预测按需分配和回收KV Cache, 避免固定显存预留造成的浪费。
- **系统效果:** 基于9 类LLM 多智能体应用的46,769 个工作流、144,524 个Agent 阶段进行验证; 输出长度预测MAE 相比Magnus 降低19.2%, 高负载下SLO 达成率相比EDF 提升23.6 个百分点, 为KV Cache 预留的HBM 降低67.2%。

📁 工作与实习经历

• 字节跳动

2026.02 – 2026.06

国际电商Lumen 部门 · AI Infra 工程师 (实习)

参与电商训练统一资源池调度系统建设。GPU 按团队静态切分, 部分团队任务持续排队时, 其他团队仍有数百张GPU 因配额隔离而空闲——空闲资源无法跨团队流动, 形成资源孤岛。为此在底层Merlin 训练平台之上设计跨团队二级调度框架, 通过配额、优先级与可抢占资源统一协调GPU 的借用和回收。

- **跨团队弹性调度:** 构建集群级资源与队列视图, 将团队GPU 配额与A/B/C 任务优先级纳入统一调度; 允许空闲配额以Spot 形式跨团队借用, 并在原团队需求恢复时触发资源回收, 实现“空闲可借、高优可收”的弹性资源池。
- **代价感知抢占:** 面向资源回收场景, 根据任务类型、GPU 利用率 (SM Active)、已运行时长等特征评估抢占代价, 在满足目标释放GPU 数量的前提下选择低代价任务组合, 减少已执行计算损失和不必要的任务中断。
- **调度控制面:** 设计任务从提交、排队、调度、运行到终止的生命周期状态机, 以MySQL 持久化任务/配额状态、Redis 维护调度热数据, 并通过Thrift RPC 对接Merlin 执行层, 完成任务下发、状态同步与资源回收。
- **状态闭环与监控:** 构建事件驱动的任务状态同步与监控机制, 对任务状态变更、团队配额和实际资源占用进行持续对账, 并检测执行异常, 为调度器资源视图和后续决策提供实时反馈。

字节跳动

2021.07 – 2022.10

商业化技术部门 · 后端开发工程师 (全职)

负责TikTok 企业号商业化产品后端研发, 参与企业认证、Business Suite、充值及私信等核心业务, 从需求评审、技术方案设计到开发上线及线上维护的全流程交付。

- **企业认证与商业工具:** 设计并实现蓝V 企业认证流程、认证状态及权益管理, 并参与Business Suite 等企业号商业工具建设, 完成核心数据模型、业务流程及上下游接口设计。
- **充值与私信业务:** 负责企业号Web 端充值及私信业务后端设计与开发, 完成核心交易/消息流程、状态管理及上下游系统联调, 支撑功能上线与持续迭代。
- **业务交付与稳定性:** 负责相关服务的版本迭代、线上问题排查与跨团队联调, 持续完善异常处理和接口兼容性, 保障业务稳定运行。

• 字节跳动

2020.12 – 2021.02

商业化技术部门 · 后端开发工程师 (实习)

参与TikTok 广告归因业务及Google / Facebook 高价值用户数据回传, 使用Python 优化数据处理流程, 保障数据传输准确性与系统稳定性。

• 北京中科寒武纪科技有限公司

2019.03 – 2019.07

软件部 · 深度学习算法工程师 (实习)

参与TensorFlow 框架对寒武纪MLU 加速芯片的算子适配与模型支持, 深入AI 加速卡底层做算子开发与性能调优。

- 面向MLU 架构开发深度学习算子并接入TensorFlow，结合芯片访存层次与并行特性做计算切分、算子融合与数据布局优化，扩展框架在国产加速卡上的算子覆盖并提升硬件利用率。
- 在MLU 上完成CRNN 等模型的端到端调试与精度对齐，定位并修复算子级数值与性能问题，保障模型在目标平台正确高效运行（C++）。

🔧 专业技能

- 编程语言 | Go、Python、C/C++、Shell（Go / Python 工业级工程经验）
- 云原生 | Kubernetes（自研调度器与Operator）、Helm、Docker、Prometheus / Grafana、Linux 运维
- 机器学习 | PyTorch、ONNX、GNN、Transformer / LLM 推理优化（vLLM、KV Cache、调度共置）
- 研究方向 | 资源调度与优化（启发式 / 在线 / 学习驱动）、性能预测、LLM 系统、AI Infra
- 学术与语言 | 独立英文论文写作、软件著作权与专利申请；CET-6

♥ 获奖情况

- 2026：北航ACT 实验室研究生创新奖学金、北航校友奖学金——航空工业奖学金二等奖、北京航空航天大学研究生学业奖学金二等奖
- 2025：北航“冯如杯”竞赛研究生组主赛道一等奖、中国国际大学生创新大赛北京赛区二等奖、中国研究生操作系统开源创新大赛三等奖、北京航空航天大学优秀学生干部、北京航空航天大学研究生学业奖学金二等奖
- 2024：北京航空航天大学国睿奖学金、优秀研究生、优秀三好学生、研究生学业奖学金二等奖
- 2023：北京航空航天大学研究生学业奖学金一等奖、优秀学生干部
- 2018–2020：北京航空航天大学研究生学业奖学金二等奖（连续三年）

📖 兴趣与其他

- 研究聚焦GPU 集群资源调度与LLM 系统，擅长将模糊需求转化为可量化指标并验证，能独立完成研究、英文论文写作及原型工程化与开源。
- 担任开源平台负责人、博士班班长及《云计算技术》《国产基础软件》课程助教，注重长期投入与团队协作。
- 运动爱好者：健身、乒乓球、羽毛球、长跑、游泳，参加过多场马拉松和越野比赛——长跑教会我把节奏交给过程。